

Pythonで学ぶ
ベイズ推論ハンズオン（後編）
【ベイズ統計モデリングに慣れる】

<https://github.com/Ronmemo/Beyes>

本日の予定

7/28 (日) 後編【ベイズ統計モデリングに慣れる】

ベイズ推論の基礎続き

- 事前分布と事後分布の関係
- MCMC法とは何か, その他の近似法
- 予測分布の求め方
- Python (PyMC3) によるベイズ推論の実装, より詳しく中身を見る

さまざまなモデルにおけるベイズ推論

- 正規分布モデル
- 線形回帰モデル
- ロジスティック回帰モデル
- 階層モデル
- 混合分布モデル

ベイズ推論の基礎 (続き)

ベイズ推論の流れ（再掲）

学習

1. データの特徴をつかむ

2. モデルを決める

3. 事後分布を求める

ベイズの定理

$$p(\theta | D) = \frac{p(D | \theta)p(\theta)}{p(D)}$$

推論

4. 予測分布を求める

$$p(x_* | D) = \int p(x_* | \theta)p(\theta | D)d\theta$$

1. データの特徴をつかむ

例：コインを投げて， 5回中2回表が出た
→表が出る確率は？

表1， 裏0とすると
0,1,0,0,1
と表せる

2. モデルを決める

ベルヌーイ分布（二項分布）

でモデリングする

尤度 $L(\theta | X) = p(X | \theta) = \text{Bern}(X | \theta)$

→ データを示す

事前分布

$p(\theta) = \text{Beta}(\theta | a, b)$

→ 既知の情報を示す

ベータ分布は
二項分布に対して
共役である

＊ X : 訓練データ集合 θ : パラメータ

事前分布としてのベータ分布

<https://ryosuke-okubo.hatenablog.com/entry/2019/03/07/210000>

3. 事後分布を求める

条件付き確率

$$p(X, \theta) = p(X | \theta)p(\theta)$$

ベイズの定理

事前分布

$$p(\theta | X) = \frac{p(X | \theta)p(\theta)}{p(X)}$$

周辺分布

共役事前分布の利点


X1を観測した後の事後分布

$$p(\theta | X_1) \propto p(X_1 | \theta) p(\theta)$$

その後、X2を観測した後の事後分布

$$p(\theta | X_1, X_2) \propto p(X_2 | \theta) p(\theta | X_1)$$

共役事前分布を用いると、
全て同じ形の確率分布が
出力される



解析解を出すのが楽

例：ベルヌーイ分布

https://ryosuke-okubo.hatenablog.com/entry/2019/03/11/210000_1

コイン投げ問題の例

[1] 一般モデルの推定

まず偏りの概念を一般化する。

- 偏りが0→裏しか出ない
- 偏りが1→表しか出ない
- 偏りが0.5→表と裏が半々出る

偏りのパラメータを θ 、N回投げて表が出た回数を y とすると、次の式で表される。

$$p(\theta|y) \propto p(y|\theta)p(\theta)$$

[2] 尤度の選択

コイン投げの試行において、尤度は**2項分布**となる。

$$p(y|\theta) = \binom{N}{y} \theta^y (1 - \theta)^{N-y}$$

[3] 事前分布の選択

ベータ分布を用いる。

$$p(\theta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^\alpha (1 - \theta)^{\beta-1}$$

ベータ分布を使う理由として、

- 0と1の区間に制限されている
- パラメータによって様々な形をとる
- 2項分布の共役事前分布である

ことがあげられる。

[4] 事後分布の計算

ベイズの定理より、

$$p(\theta|y) \propto \binom{N}{y} \theta^y (1 - \theta)^{N-y} \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^\alpha (1 - \theta)^{\beta-1}$$

θ に依存する項のみで簡略化すると、

$$p(\theta|y) \propto \theta^{\alpha-1+y} (1 - \theta)^{\beta-1+N-y}$$

つまり、次のベータ分布で表される。

$$p(\theta|y) = \text{Beta}(\alpha_{\text{prior}} + y, \beta_{\text{prior}} + N - y)$$

実際、コンピューターでは

近似解を求める方法

- サンプルング (**MCMC**)
 - メトロポリス-ヘイスティングス**
 - ノーUターンサンプラー**
 - ギブスサンプリング
 - ハミルトニアンモンテカルロ
 - 逐次モンテカルロ
- 簡単な式に変換する周辺化計算の近似
 - 変分推論
 - ラプラス近似
 - 期待値伝播

MCMC法とは？

Monte Carlo + Markov chain

モンテカルロ法


→ 乱数を用いた近似方法

マルコフ連鎖

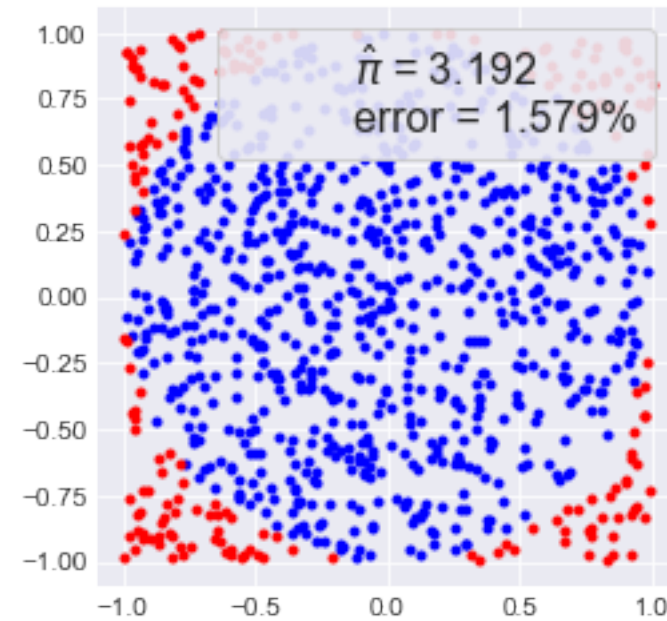
→ 現在の状態が決まっていれば、
過去および未来の状態は独立である
確率過程（離散）

$$\begin{aligned} P(x_{t+1} | x_1, x_2, \dots, x_t) \\ = P(x_{t+1} | x_t) \end{aligned}$$


モンテカルロ法の例



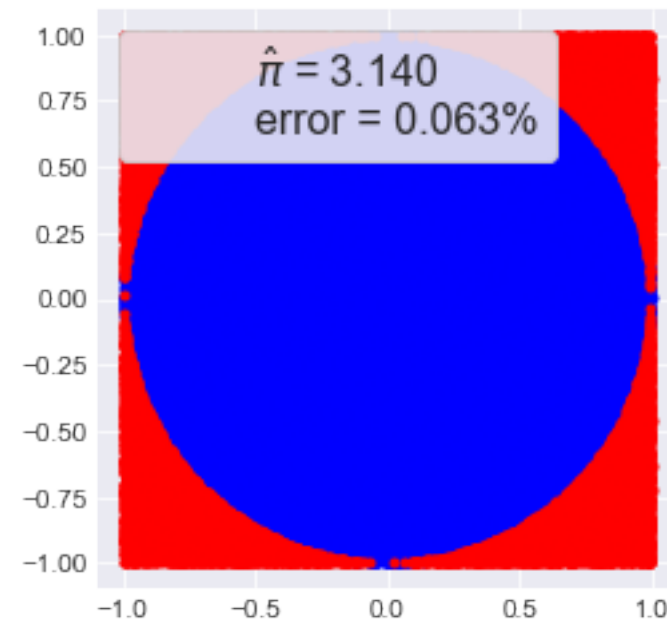
N = 100



N = 1000



N = 10000



N = 100000


マルコフ連鎖の例

ランダムウォーク

$$P(x_{t+1} | x_1, x_2, \dots, x_t)$$

$$= P(x_{t+1} | x_t)$$

→ **1 or -1**



メトロポリス-ヘイスティングス

ベイジアン分析は、主にマルコフ連鎖モンテカルロ（MCMC）法によって実行される。マルコフ連鎖において、メトロポリス-ヘイスティングス・アルゴリズムが汎用される。アルゴリズムの手順を以下に示す。

1. パラメータ x_i の初期値を決める
2. 新しいパラメータの値 x_{i+1} を決め、サンプリングが簡単な分布（例：正規分布） $Q(x_{i+1} | x_i)$ からサンプルを得る。
3. メトロポリス-ヘイスティングスの基準

$$p_a(x_{i+1} | x_i) = \min\left(1, \frac{p(x_{i+1})q(x_i | x_{i+1})}{p(x_i)q(x_{i+1} | x_i)}\right)$$

を使って、新しいパラメータの値を受け入れる確率を計算する。



4. 3.で計算された確率が区間 $[0,1]$ の一様分布から得られる値より大きい場合、新しい状態を受容して、そうでなければ古い状態に留まる。
5. 1.から4.を繰り返す。

最終的に、サンプルチェーン（サンプルトレース）という数値リストを得る。これは事後分布の近似である。



サンプリングの様子

$\beta(1,4)$

集計すると、
確率分布の近似が
得られる



最初の1000ステップ



より高い確率の方に
移動しようとする

4. 予測分布を求める

$$p(x_* | D) = \int p(x_* | \theta) p(\theta | D) d\theta$$

未知の
データ

→ さまざまな θ について
モデルの平均

Python (PyMC3) による
ベイズ推論の実装,
より詳しく中身を見る

さまざまなモデルに
おけるベイズ推論